Guia do Projeto

Spectral Window Dependence in Stellar Parameter Inference of M Dwarfs

---

Josué Araújo, Cleber da Silva Filho, Sarah Barbosa, Daniel Brito de Freitas

2025

Conteúdo

1 Entendendo o problema **2**

2 Entendendo o problema **2**

3 O que já foi feito **3**

3.1 O baseline . . . 3

3.2 O que o baseline não fez . . . 3

3.3 Por que usar o Korg e não o PHOENIX? . . . 4

4 Passo 1 - Atualização do datagen.py e geração dos dados **5**

4.1 O que mudou no `datagen.py` . . . 5

4.1.1 Relação massa-raio de Schweitzer et al. (2019) . . . 5

4.1.2 Distribuição gaussiana para [Fe/H] . . . 6

4.2 As janelas candidatas . . . 6

4.3 Adicionando a degradação instrumental . . . 8

5 Passo 2 - Treinar os modelos por janela **9**

5.1 Passos . . . 9

5.2 O que registrar . . . 10

6 Passo 3 - Comparar e interpretar os resultados **10**

6.1 As figuras que o notebook precisa produzir . . . 10

7 Passo 4 - Aumentar o realismo progressivamente **11**

7.1 Como implementar o broadening rotacional . . . 12

8 Passo 5 - Implicações para a caracterização de exoplanetas **13**

8.1 Cálculo 1: erro em T_{eff} e a zona habitável . . . 13

8.2 Cálculo 2: erro em $\log g$ e o raio do planeta . . . 13

8.3 Cálculo 3: erro em [Fe/H] e a frequência de planetas . . . 14

8.4 A figura síntese . . . 14

9 Passo 6 - Comparação qualitativa com espectros observados **15**

9.1 Quais estrelas usar . . . 15

1 Entendendo o problema

2 Entendendo o problema

Imagine que você quer saber do que é feita uma estrela anã M: pequena, avermelhada, bem mais fria que o Sol. Você não pode ir até ela. O que dá pra fazer é analisar a luz que ela emite. Quando essa luz passa por um espectrógrafo, ela se separa em comprimentos de onda e forma um espectro cheio de linhas escuras. Cada linha corresponde a um elemento químico ou uma molécula presente na atmosfera da estrela, como uma impressão digital.

A partir dessas linhas dá pra derivar três parâmetros fundamentais que descrevem a estrela: temperatura efetiva ($T_{\rm eff}$), que indica o quão quente ela é; gravidade superficial ($\log g$), que reflete compactação da estrela; e metalicidade ([Fe/H]), que mede a abundância de elementos pesados em relação ao hidrogênio. Juntos, esses três números formam o que chamamos de caracterização estelar. E isso importa especialmente para anãs M porque são essas estrelas que mais hospedam planetas rochosos na zona habitável, a faixa de distâncias em que a água líquida pode existir na superfície de um planeta.

O problema é que medir esses parâmetros a partir do espectro de uma anã M não é simples. O espectro dessas estrelas é dominado por bandas moleculares que se sobrepõem umas às outras, deixando pouco contínuo visível para ancorar a análise. Regiões diferentes do espectro carregam quantidades diferentes de informação astrofísica, e os modelos que usamos para comparar com as observações, os chamados espectros sintéticos, nunca reproduzem o espectro real com perfeição. Essa diferença entre sintético e observado tem um nome: **gap sintético**. Ignorá-lo pode levar a estimativas erradas dos parâmetros estelares.

É aí que entra esse projeto que você definiu junto com o Cleber. O que estamos investigando é qual região do espectro, qual **janela espectral**, fornece a melhor recuperação dos parâmetros estelares quando usamos redes neurais convolucionais treinadas com espectros sintéticos gerados pelo Korg. E, uma vez respondido isso, a pergunta seguinte é o que acontece com a estimativa de propriedades de exoplanetas quando a janela espectral escolhida é melhor ou pior?

Questão científica central: dentre um conjunto de janelas espectrais candidatas, qual delas melhor recupera $T_{\rm eff}$, $\log g$ e [Fe/H] de anãs M em um benchmark sintético gerado com Korg, ajustado à resolução do espectrôgrafo CARMENES?

3 O que já foi feito

Antes de entrar no passo a passo do que vem pela frente, vale entender o que já existe no repositório. Cada decisão tomada até aqui foi intencional, e conhecer o raciocínio por trás delas facilita entender o que ainda falta fazer.

3.1 O baseline

O baseline foi a fase de prova de conceito do projeto (o que foi apresentado na SAB). A ideia era responder se uma CNN 1D treinada com espectros sintéticos do Korg consegue recuperar os parâmetros estelares de anãs M com boa precisão. Para testar isso sem introduzir variáveis desnecessárias, usamos apenas a janela 8800-8835 Å, a mesma que a literatura aponta como a mais informativa para anãs M em espectros PHOENIX. Os resultados foram melhores do que o esperado:

Parâmetro	$\mathbf{R^2}$	**MAE**	**RMSE**
$T_{\rm eff}$ [K]	0.999	$\approx$6 K	$\approx$8.5 K
$\log g$ [cgs]	0.998	$\approx$0.010	$\approx$0.013
[Fe/H] [dex]	0.999	$\approx$0.010	$\approx$0.014

As três métricas medem coisas distintas. O R^2 diz o quão bem o modelo explica a variância dos dados, onde 1 é perfeição absoluta. O MAE é o erro médio absoluto nas predições. O RMSE faz a mesma coisa, mas penaliza erros grandes com mais peso. Os três juntos apontando para valores próximos de 1 indicam que o modelo está ajustando bem na média e também não está cometendo erros grandes em casos específicos.

O modelo convergiu em cerca de 27 épocas sem sinal de overfitting. Esses resultados são consistentes com os de Bello-García et al. (2023) para a mesma região espectral com PHOENIX, o que serve indica que o pipeline de síntese com Korg está correto, e a arquitetura CNN está aprendendo o que deveria aprender.

3.2 O que o baseline não fez

O baseline foi simplificado de propósito para validar a arquitetura antes de qualquer outra coisa. Mas cada simplificação deixada pra trás define exatamente o que a próxima fase precisa endereçar:

- **Sem degradação instrumental:** os espectros Korg foram usados na resolução nativa, sem convolução para $R \approx 94\,600$ do CARMENES. Isso significa que o modelo treinou numa resolução que nenhum espectro real do instrumento vai ter.
- **Sem broadening rotacional:** $v \sin i$ foi ignorado. Estrelas reais giram, e isso alarga as linhas espectrais de forma mensurável, especialmente para rotadores rápidos.
- **Sem ruído:** os espectros de treino são perfeitamente limpos. Espectros reais têm ruído gaussiano que depende do SNR da observação.
- **Apenas uma janela:** não há comparação entre regiões espectrais. Esse é o objetivo central da próxima fase.
- **Raio e metalicidade amostrados uniformemente:** a versão anterior do `datagen.py` usava distribuições uniformes para raio e [Fe/H]. O código foi atualizado (ver Passo 4).

O baseline não é errado: é simplificado de propósito. Esse valor alto no R^2 é esperado no domínio sintético puro, onde o modelo treina e testa em dados gerados pela mesma física. O desafio real começa quando esses modelos encontram espectros observados, porque aí o gap sintético aparece. O modelo nunca viu imperfeições reais durante o treino, e essa diferença pode enviesar os parâmetros recuperados de formas que os números de treino não mostram.

3.3 Por que usar o Korg e não o PHOENIX?

PHOENIX é o código de síntese espectral mais usado na literatura para anãs M. Ele é a referência dos trabalhos de Passegger et al. (2020) e Bello-García et al. (2023), e boa parte do que sabemos sobre janelas espectrais informativas vem de estudos que usaram espectros PHOENIX como base. O Korg é um código mais recente que também assume equilíbrio termodinâmico local (LTE) unidimensional como simplificação da estrutura atmosférica, mas trata opacidades e listas de linhas de forma diferente. Na prática, isso significa que os dois códigos podem gerar espectros sintéticos com diferenças sutis mas mensuráveis nas mesmas condições atmosféricas.

Usar o Korg nesse projeto serve a dois propósitos. O primeiro é metodológico. A janela 8800-8835 Åfoi identificada como ótima em estudos baseados em PHOENIX. Mas essa conclusão depende do código de síntese adotado? Se o ranking de janelas mudar quando trocamos de PHOENIX para Korg, isso indica que a chamada janela ótima não é uma propriedade do espectro estelar em si mas sim ser uma propriedade do modelo atmosférico que usamos pra descrever esse

espectro. Esse resultado teria implicações diretas para qualquer análise espectroscópica de anãs M, porque sugere que a escolha do código de síntese afeta não só os parâmetros recuperados, mas também a estratégia de observação. O segundo é prático. O Korg está em desenvolvimento ativo, tem documentação aberta e uma interface Python/Julia limpa que facilita a integração com o resto do pipeline. Do ponto de vista de reprodutibilidade, isso torna o projeto mais fácil verificar, de estender e de usar como ponto de partida pra trabalhos futuros.

4 Passo 1 - Atualização do datagen.py e geração dos dados

O primeiro passo da fase de análise de janelas é gerar os datasets para todas as janelas candidatas. O `datagen.py` foi atualizado desde o baseline com duas mudanças importantes que tornam os espectros sintéticos mais fisicamente realistas.

4.1 O que mudou no `datagen.py`

Duas mudanças foram feitas no `datagen.py` desde o baseline. Tentei fazer os espectros sintéticos se comportarem mais como espectros de anãs M reais, em vez de preencher uniformemente um espaço de parâmetros que não reflete o que a natureza produz.

4.1.1 Relação massa-raio de Schweitzer et al. (2019)

No baseline, massa e raio eram amostrados de forma independente. Na prática, isso significa que o dataset incluía combinações como uma estrela muito massiva com raio pequeno, ou uma pouco massiva com raio grande. Essas combinações não existem. Anãs M seguem uma relação massa-raio bem definida, em que estrelas mais massivas são também maiores, com pouca dispersão em torno dessa tendência. O código agora usa a equação 7 de Schweitzer et al. (2019), A&A 625, A68:

$$\frac{R}{R_\odot} = 0.0282 + 0.935 \cdot \frac{M}{M_\odot} \qquad \left(\text{rms} \approx 0.02\, R_\odot\right) \tag{1}$$

Na prática, a função `radius_from_mass(mass_msun)` sorteia a massa, calcula o raio correspondente pela equação acima e adiciona um ruído gaussiano de $\sigma = 0.02\, R_\odot$ para simular a dispersão observada ao redor da relação. O resultado é que os pares (M, R) do dataset ficam distribuídos ao longo da sequência principal das anãs M, não espalhados por um retângulo arbitrário no espaço de parâmetros.

Vale notar que isso também afeta $\log g$, que é calculado diretamente de M e R via $g = GM/R^2$.

Com a relação massa-raio imposta, a gravidade superficial do dataset passa a ter a distribuição que anãs M reais apresentam, em vez de uma distribuição artificial herdada de uma amostragem uniforme e independente.

4.1.2 Distribuição gaussiana para [Fe/H]

No baseline, a metalicidade era amostrada uniformemente no intervalo $[-0.5, +0.5]$ dex (lembro que foi adotado "de cabeça"). O problema com isso é que a amostragem uniforme trata uma estrela com $[\mathrm{Fe/H}] = -0.5$ como tão provável quanto uma com $[\mathrm{Fe/H}] = 0.0$, quando na vizinhança solar a realidade é que estrelas com metalicidade próxima da solar são muito mais comuns do que estrelas muito metal-pobres ou muito metal-ricas.

O código agora amostra [Fe/H] de uma gaussiana com média $\mu = -0.05$ dex e desvio padrão $\sigma = 0.20$ dex, baseada nos dados de Bonfils et al. (2007), A&A 474, 293. O valor é depois recortado ao intervalo permitido com `np.clip`. Com isso, distribuição de metalicidade do dataset passa a refletir o que é observado em populações reais de anãs M na vizinhança solar.

Essas duas mudanças tornam o dataset mais realista, mas também alteram a distribuição das amostras. Se você comparar histogramas do baseline com os da nova fase (ver Figura 1), vai notar diferenças na distribuição de $\log g$ *(porque ele é calculado de M e R) e de [Fe/H]. E importante! Eu rodei o baseline inteiro (geração + modelagem) com essa na distribuição e subi na branch de dev.*

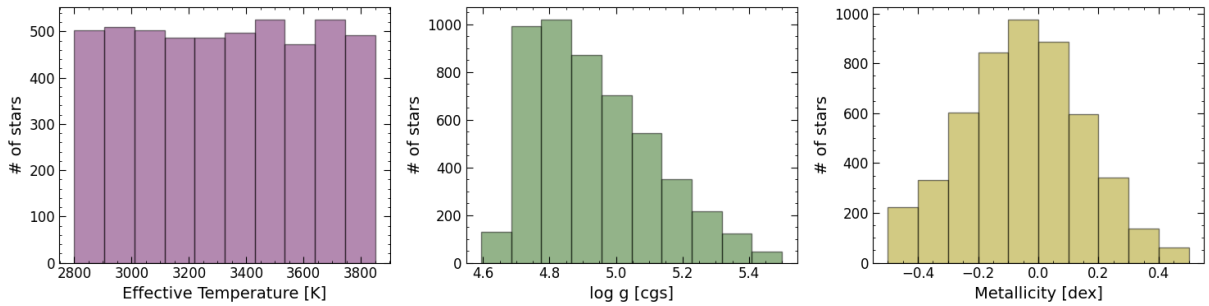


Figura 1: Distribuições dos parâmetros.

4.2 As janelas candidatas

O coração do projeto é a comparação de janelas espectrais. Aqui escolhi cinco janelas espectrais onde cada uma foi escolhida porque responde a um regime físico diferente: algumas são sensíveis principalmente à temperatura, outras à gravidade, outras à metalicidade.

Janela [Å]	Região	Por que esta janela?
8800-8835	VIS - Ca II IRT	Controle positivo. Passegger et al. (2020) e Bello-García et al. (2023) identificaram essa região como a de menor erro de validação em PHOENIX. É a referência contra a qual as outras janelas serão comparadas.
8640-8710	VIS - Ca II IRT	Ala do mesmo triplete do Ca II. Sensível a $T_{\rm eff}$ e $\log g$, mas diferente o suficiente para não ser redundante com a janela anterior.
8160-8225	VIS - TiO + Na I	Dominada por bandas moleculares de TiO, muito sensíveis a $T_{\rm eff}$ em anãs M frias. Contém também linhas de Na I sensíveis a [Fe/H].
7640-7725	VIS - K I + TiO	Linhas de K I e TiO. O potássio é sensível a $\log g$ e [Fe/H], e a região é bem estudada para anãs M tardias.
9719-9735	NIR - Pa ε	Linha de Paschen do hidrogênio, sensível principalmente a $T_{\rm eff}$. É a janela mais estreita e com menos linhas das cinco: funciona como controle comparativo pra avaliar o que acontece quando a informação disponível é escassa.

Uma decisão importante na geração dos dados é sortear os parâmetros estelares uma única vez e usar esses mesmos parâmetros para sintetizar o espectro em cada janela separadamente. Queremos que a comparação entre janelas seja feita sobre a mesma amostra de estrelas. Se cada janela tivesse seus próprios parâmetros sorteados de forma independente, qualquer diferença no desempenho dos modelos poderia ser resultado da aleatoridade amostral, não da janela em si. Compartilhar os parâmetros elimina essa confusão.

O que fazer

Você cria um notebook, por exemplo, `01_datagen_windows.ipynb` (em `notebooks/spectral_windows_analysis/`), implementa a geração de dados para todas as janelas. Sorteie os parâmetros estelares uma única vez e sintetize o espectro de cada janela com esse mesmo conjunto de parâmetros. O notebook deve gerar um arquivo Parquet por janela.

4.3 Adicionando a degradação instrumental

O baseline usou espectros Korg na resolução nativa do código de síntese, que é muito mais alta do que qualquer espectrôgrafo real consegue medir. Isso cria um problema: se treinarmos um modelo com espectros nessa resolução e depois tentarmos aplicá-lo a espectros do CARMENES, o modelo vai encontrar linhas mais largas e borradas do que as que viu durante o treino. A degradação instrumental corrige isso antes que os dados cheguem ao modelo.

O que é resolução espectral R? É a capacidade do instrumento de separar dois comprimentos de onda próximos, definida como $R = \lambda/\Delta\lambda$. Para o CARMENES ($R \approx 94\,600$) em torno de $\lambda = 8800$ Å, isso corresponde a um elemento de resolução de $\Delta\lambda \approx 0.093$ Å. Qualquer estrutura espectral mais fina do que isso não é detectável pelo instrumento e o espectrôgrafo a borra. A forma mais direta de simular esse borramento é convolver o espectro com um perfil gaussiano cuja largura corresponde ao FWHM instrumental.

Na prática, a convolução é feita no espaço de pixels. Calculamos o FWHM em ângstrons a partir de R e do comprimento de onda central da janela, convertemos para pixels usando o passo da grade de comprimentos de onda, e depois convertemos de FWHM para σ gaussiano dividindo por $2\sqrt{2\ln 2} \approx 2.355$:

```
from scipy.ndimage import gaussian_filter1d

def degrade_to_carmenes(wavelength_A, flux, R=94600):
    lam_center = np.mean(wavelength_A)
    fwhm_A = lam_center / R
    dpix = wavelength_A[1] - wavelength_A[0]
    sigma_pix = (fwhm_A / dpix) / 2.355
    return gaussian_filter1d(flux, sigma=sigma_pix)
```

Crie um arquivo `src/preprocessing.py` para essa função. A ordem seria:

$$\text{síntese} \rightarrow \text{degradação instrumental} \rightarrow \text{normalização} \rightarrow \text{salvar}$$

A degradação vem antes da normalização porque o borramento gaussiano afeta a forma do contínuo e a profundidade das linhas. Normalizar antes de degradar produziria um espectro ligeiramente diferente de normalizar depois, e a ordem correta é a que simula o que o instrumento faz: ele recebe o fluxo físico e o borra, e só depois normalizamos para fins de análise.

5 Passo 2 - Treinar os modelos por janela

Com os cinco datasets gerados, o próximo passo é treinar um modelo por janela e registrar o desempenho de cada um no mesmo conjunto de teste.

5.1 Passos

Comparar o desempenho de cinco modelos só faz sentido se todos foram avaliados nas mesmas condições. Qualquer assimetria no processo de treino ou avaliação pode criar diferenças de desempenho que não têm nada a ver com a janela espectral em si. As condições abaixo eliminam essas fontes de confusão uma por uma.

- **Mesmo conjunto de teste:** use uma seed única em todos os splits. Como os Parquets foram gerados com os mesmos parâmetros estelares, as linhas de índice 0 a N correspondem às mesmas estrelas em todas as janelas. O split com seed fixa garante que o modelo da janela A e o modelo da janela B são testados exatamente nas mesmas estrelas. Sem isso, uma janela poderia parecer melhor simplesmente porque caiu com casos mais fáceis no teste.
- **Mesmo orçamento de busca:** use os mesmos valores de `MAX_TRIALS` e `SEARCH_EPOCHS` para todas as janelas. Dar mais tentativas de busca para uma janela seria uma vantagem injusta: o modelo teria mais chances de encontrar uma boa configuração de hiperparâmetros não porque a janela é melhor, mas porque teve mais tempo para procurar.
- **Mesmo número de épocas finais:** use o mesmo `EPOCHS` e `PATIENCE` para o treinamento final. A lógica é a mesma: modelos com mais épocas disponíveis têm mais oportunidade de convergir para um mínimo melhor.
- **Arquitetura idêntica:** não modifique o `HyperTuningBayCNN` entre janelas. A busca Bayesiana pode e deve encontrar hiperparâmetros diferentes para cada janela, porque janelas com mais linhas ou mais largura espectral podem se beneficiar de arquiteturas ligeiramente distintas. Mas a classe que define o espaço de busca deve ser a mesma para todas.

Sugiro demais você pagar pelo menos uma vez o Google Colab para testar esses modelos (deixei o notebook 002 já pronto para rodar no Colab), se não me engano está 58 reais.

O que fazer

No notebook `02_training_windows.ipynb`, implemente um loop sobre as janelas. Para cada janela: (1) carregue o Parquet; (2) gere os splits com `prepare_splits(..., random_state=42)`; (3) execute a busca Bayesiana; (4) treine o modelo final; (5) avalie no conjunto de teste; (6) salve R^2, MAE e RMSE em `results/window_comparison.csv`. Salve os resultados parciais a cada janela concluída: o treinamento compleo pode levar muitas horas, e perder progresso por uma interrupção no meio seria custoso.

5.2 O que registrar

A tabela de resultados tem uma linha por combinação janela-parâmetro. Isso significa quinze linhas no total: cinco janelas, três parâmetros cada. Esse formato longo é mais fácil de filtrar e visualizar do que um formato largo com uma coluna por métrica por parâmetro.

window	parameter	R^2	MAE	RMSE
8800_8835	Teff_K	0.999	6.1	8.4
8800_8835	logg_cgs	0.998	0.010	0.013
8800_8835	FeH_dex	0.999	0.010	0.014
8640_8710	Teff_K	...	...	...
...				

6 Passo 3 - Comparar e interpretar os resultados

Este é o notebook de análise, digamos `03_window_comparison.ipynb`. Ele não treina nada e não gera dados novos: lê o `results/window_comparison.csv` produzido no passo anterior e gera as figuras que respondem à questão científica central do projeto.

6.1 As figuras que o notebook precisa produzir

Pensei no seguinte:

1. **Barplot de MAE por janela e por parâmetro:** três painéis lado a lado, um para cada parâmetro ($T_{\rm eff}$, $\log g$, [Fe/H]), com barras representando as cinco janelas em cada painel. Essa figura responde qual janela comete menos erro, em média, para cada parâmetro.

2. **Mapa de calor (janela $\times$ parâmetro):** MAE normalizado, onde 0 é o melhor desempenho e 1 é o pior para cada parâmetro. A normalização é necessária porque T_{eff}, $\log g$ e [Fe/H] têm escalas completamente diferentes: comparar um MAE de 6 K com um de 0.010 dex diretamente não faz sentido. Com tudo na mesma escala, os trade-offs ficam visíveis, uma janela pode ser excelente para T_{eff} e ao mesmo tempo fraca para [Fe/H].

3. **Distribuição de resíduos:** violin plots de (predito $-$ verdadeiro) por janela. O MAE diz quanto o modelo erra em média, mas não diz como esses erros estão distribuídos. Os violin plots revelam se os erros são simétricos em torno de zero (sem viés sistemático), se há caudas longas em uma direção (viés para estrelas frias, por exemplo) e se existem outliers que o MAE está mascarando.

4. **Scatter true vs. predito:** para a melhor e a pior janela em cada parâmetro. Um R^2 alto pode esconder comportamentos ruins em regiões específicas do espaço de parâmetros. O scatter plot mostra isso diretamente: se as predições se afastam da diagonal em alguma faixa de T_{eff} ou [Fe/H], isso aparece aqui, e não no MAE.

A ideia é ver por exemplo, será que a banda que tá sendo usada como baseline ainda continua sendo a melhor para o Korg também. Se tem outra janela melhor. Se existe um tipo de ranking para diferentes tipos de parâmetros...

7 Passo 4 - Aumentar o realismo progressivamente

Com o ranking de janelas estabelecido no cenário limpo, o próximo objetivo é verificar se esse ranking se mantém quando os espectros ficam mais parecidos com o que um espectrôgrafo real produziria. Na minha cabeça, os passos anteriores é bem rápido para fazer, mas se achar que não, pode morrer nessa parte. Mas cada adição de realismo é um experimento separado, e a ordem importa: queremos saber exatamente qual elemento físico muda o ranking, e isso só é possível se adicionarmos um elemento de cada vez.

A lógica é a seguinte. Se a janela X é a melhor no cenário limpo mas perde essa posição quando adicionamos ruído, isso diz algo específico: ela carrega informação astrofísica real, mas essa informação fica enterrada quando o espectro tem qualidade fotométrica limitada. Uma janela assim pode ser excelente para telescópios grandes e observações longas, mas problemática para surveys com tempo de exposição restrito.

Notebook	O que adiciona	Por que importa
`04a_with_rotation`	Broadening rotacional: $v \sin i = 2, 5, 10$ km/s	Estrelas giram e isso alarga as linhas. Janelas dominadas por linhas naturalmente mais largas sofrem menos com esse efeito do que janelas com linhas estreitas.
`04b_with_noise`	Ruído gaussiano: S/N $= 50, 100, 150$	Uma janela que funciona bem com S/N $= 50$ é mais útil na prática do que uma que só performa bem com S/N > 200. Esse experimento mapeia onde cada janela começa a degradar.

7.1 Como implementar o broadening rotacional

Quando uma estrela gira, diferentes partes da fotosfera se movem em relação ao observador com velocidades distintas. A parte que se aproxima tem seus comprimentos de onda deslocados para o azul; a que se afasta, para o vermelho. O resultado é que cada linha espectral fica alargada pelo efeito Doppler integrado sobre o disco estelar. Esse alargamento é mais largo no centro e tem bordas mais pronunciadas, porque as regiões do limbo (borda do disco) têm componente radial de velocidade próxima de zero e contribuem com mais fluxo nessa posição do perfil.

A implementação pode ser usada usando a função `rotBroad` da biblioteca PyAstronomy, que implementa o perfil de Gray (1992) com coeficiente de escurecimento de limbo $\varepsilon = 0.6$. O parâmetro ε controla quanto o centro do disco contribui em relação ao limbo: o valor 0.6 é o padrão adotado na literatura para estrelas de tipo solar a anãs M.

```
from PyAstronomy.pyasl import rotBroad

def apply_rotation(wavelength_A, flux, vsini_kms, epsilon=0.6):
    return rotBroad(wavelength_A, flux, epsilon, vsini_kms)
```

8 Passo 5 - Implicações para a caracterização de exoplanetas

A ideia aqui não é fazer novas análises de sistemas planetários: é mostrar que os erros nos parâmetros estelares, que variam de janela para janela, têm consequências quantificáveis para o que concluímos sobre os planetas ao redor dessas estrelas. Parâmetros estelares errados produzem parâmetros planetários errados.

Ai você cria um notebook chamado, por exemplo, `05_implications_for_exoplanets.ipynb` e não treina nenhum modelo e não gera espectros. Aqui você apenas carrega apenas o `results/window_comparison.csv` e executa três cálculos de propagação de erro, um para cada parâmetro estelar. A única entrada são os MAEs do passo anterior.

8.1 Cálculo 1: erro em T_{eff} e a zona habitável

A zona habitável é definida pelos limites de distância orbital em que a irradiação estelar permite a existência de água líquida na superfície de um planeta. Esses limites dependem da luminosidade da estrela, que por sua vez depende fortemente da temperatura efetiva: $L \propto R^2 T_{\text{eff}}^4$. Um erro em T_{eff} se propaga para a luminosidade como:

$$\frac{\Delta L}{L} \approx 4 \cdot \frac{\Delta T_{\text{eff}}}{T_{\text{eff}}} \tag{2}$$

Os limites da zona habitável escalam com a raiz quadrada da luminosidade, então o erro no raio orbital dos seus limites é:

$$\frac{\Delta d_{\text{ZH}}}{d_{\text{ZH}}} \approx 2 \cdot \frac{\Delta T_{\text{eff}}}{T_{\text{eff}}} \tag{3}$$

Para uma anã M típica com $T_{\text{eff}} \approx 3300$ K e zona habitável em $d \approx 0.1$ UA, o MAE de T_{eff} de cada janela produz um deslocamento diferente em d_{ZH}. Isso importa porque zona habitável de anãs M tem largura da ordem de 0.05 UA: um erro de 0.005 UA nos seus limites já corresponde a 10% da largura total. Uma janela que comete o dobro do erro em T_{eff} do que outra pode estar deslocando os limites da zona habitável por uma fração não desprezível da sua própria largura.

8.2 Cálculo 2: erro em $\log g$ e o raio do planeta

A gravidade superficial é definida como $g = GM_\star / R_\star^2$. Assumindo que a massa estelar é conhecida com boa precisão, por exemplo via relação massa-luminosidade, um erro em $\log g$ se propaga para o raio estelar como:

$$\frac{\Delta R_\star}{R_\star} \approx \frac{1}{2}\ln(10)\cdot\Delta\log g \approx 1.15\cdot\Delta\log g \tag{4}$$

O raio estelar entra diretamente na determinação do raio planetário via profundidade de trânsito: $\delta = (R_p/R_\star)^2$. Com $R_\star$ errado em uma fração $\Delta R_\star/R_\star$, o raio planetário fica errado na mesma fração:

$$\frac{\Delta R_p}{R_p} \approx \frac{\Delta R_\star}{R_\star} = 1.15\cdot\Delta\log g \tag{5}$$

Um erro de 0.1 dex em $\log g$ implica $\approx$ 12% de erro no raio estelar e $\approx$ 25% de erro no raio planetário. Esse nível de erro é suficiente para mudar a classificação de um planeta: a fronteira entre super-Terra e mini-Netuno está em 1.6 $R_\oplus$, e um planeta medido como 1.5 $R_\oplus$ com 25% de incerteza pode igualmente ser um mini-Netuno. A escolha da janela espectral afeta diretamente essa classificação.

8.3 Cálculo 3: erro em [Fe/H] e a frequência de planetas

A frequência de planetas gigantes escala exponencialmente com a metalicidade da estrela hospedeira (Fischer & Valenti 2005):

$$f(\text{planeta}) \propto 10^{2\cdot[\text{Fe/H}]} \tag{6}$$

Essa relação é não-linear, o que significa que erros em [Fe/H] se amplificam na estimativa de frequência. Um erro Δ[Fe/H] desloca a estimativa por um fator de $10^{2\,\Delta[\text{Fe/H}]}$. Para Δ[Fe/H] = 0.05 dex, um MAE típico nesse parâmetro, esse fator é $\approx$ 26%. Janelas que cometem o dobro desse erro em [Fe/H] produzem estimativas de frequência que podem estar erradas por mais de 50%.

8.4 A figura síntese

O produto visual central deste passo é uma figura com tres painéis lado a lado, um para cada implicação:

1. Deslocamento dos limites da zona habitável (UA) por janela espectral
2. Erro no raio planetário (%) por janela espectral
3. Fator de erro na frequência de planetas por janela espectral

Em cada painel, as janelas são ordenadas do melhor ao pior desempenho. A janela com menor impacto nas três grandezas simultaneamente é a candidata a janela ótima do ponto de vista da ciência de exoplanetas. Não necessariamente será a mesma janela que tem melhor R^2 no Passo 2: uma janela pode ter MAE ligeiramente maior em $T_{\rm eff}$ mas muito menor em [Fe/H], e dependendo de quais implicações são mais relevantes para a ciência que se quer fazer, a hierarquia muda.

9 Passo 6 - Comparação qualitativa com espectros observados

Este é o passo final, e o único que sai do domínio puramente sintético. Até aqui, treinamos e avaliamos todos os modelos com espectros Korg comparados contra outros espectros Korg. Isso é útil para validar arquitetura e ranquear as janelas, mas tem uma limitação: se o código de síntese tiver algum erro sistemático, os modelos vão aprender esse erro junto com a física real, e os resultados no domínio sintético vão parecer melhores do que são. O Passo 6 é onde verificamos isso diretamente, colocando espectros sintéticos lado a lado com espectros observados de estrelas reais.

O objetivo não é derivar parâmetros precisos de estrelas reais, o que exigiria um pipeline de ajuste completo. É mostrar visualmente que o gap sintético existe e verificar se ele é diferente entre as janelas. Algumas janelas podem ter resíduos sistemáticos maiores do que outras, o que afetaria o desempenho dos modelos quando aplicados a dados reais mesmo que os resultados do Passo 2 sejam excelentes.

9.1 Quais estrelas usar

As estrelas ideais para esse exercício são aquelas cujos parâmetros são bem determinados por métodos independentes da espectroscopia, como interferometria direta ou análise de binárias FGK+M. Isso é importante porque queremos gerar o espectro sintético com os parâmetros corretos de referência e observar o gap sem ambiguidade. Se usarmos parâmetros errados, o espectro sintético vai diferir do observado por duas razões ao mesmo tempo: o gap sintético e os parâmetros incorretos. Com parâmetros interferométricos, uma dessas fontes diferença é eliminada.

Três estrelas são boas candidatas iniciais:

- **Estrela de Barnard (GJ 699):** M4.0 V, $T_{\rm eff} \approx 3224$ K. Uma das anãs M mais estudadas do céu, com parâmetros interferométricos disponíveis e espectros CARMENES de alta qualidade.

- **GJ 205:** M1.5 V, $T_{\rm eff} \approx 3827$ K. Estrela mais quente que a Barnard, útil para verificar se o gap sintético muda com a temperatura efetiva.
- **GJ 849:** M3.5 V, hospedeira de exoplaneta confirmado, com parâmetros interferométricos disponíveis. Inclui um vínculo direto com a ciência de exoplanetas do Passo 5.

Para cada janela e cada estrela, sobreponha o espectro observado com um espectro Korg sintético gerado com os parâmetros de referência, sem fazer ajuste. O que você vai ver é o gap sintético: diferenças na posição, profundidade e forma das linhas entre o observado e o sintético. Se algumas janelas tiverem um gap visivelmente menor, isso é um indicador qualitativo de que essas janelas são mais robustas para aplicação a dados reais, mesmo que o ranking quantitativo do Passo 2 não aponte nessa direção.

Este passo é o mais aberto e qualitativo do projeto. Se o tempo for curto, pode ser deixado para depois da SAB: os Passos 1 a 5 já constituem umresultado científico completo e autossuficiente. O Passo 6 adiciona contextoobservacional importante, mas sua ausência não invalida nenhuma das conclusões anteriores.